

Arquitetura de Dados e Processo de ETL Antigo

Anteriormente, nossa estrutura de arquitetura de dados seguia um processo ETL (Extração, Transformação e Carga) utilizando a API da plataforma do Brasil Participativo, as requisições eram realizadas por meio do GraphQL, mapeando os dados de forma semiestruturada em JSON. O serviço de armazenamento era constituído pelo MinIO, onde continha nosso data lake e após o tratamento e definição do esquema, o Postgres. Abaixo, está detalhado cada etapa e os principais componentes envolvidos, com foco nos problemas enfrentados e nas limitações da arquitetura.

1. Extração de Dados e Armazenamento no MinIO

Na fase de extração, utilizamos uma API GraphQL para requisitar dados diretamente da plataforma. Essa API permite consultas complexas e específicas, trazendo flexibilidade na obtenção dos dados, pois eles são definidos como semiestruturados, que apesar de não serem totalmente rígidos no esquema, seguem alguma estrutura minimalista. Após a extração, armazenamos os dados em formato JSON no MinIO, serviço que organiza os arquivos em diferentes *buckets* e zonas de armazenamento:

- **Zona *Landing*:** Nesta etapa inicial, todos os arquivos JSON extraídos são colocados na zona *landing*, que serve como área temporária de armazenamento até que sejam processados.
- **Zona *Processing*:** A partir da *landing*, os arquivos JSON são movidos para a zona *processing*, onde ocorre a transformação e o tratamento dos dados.
- **Zona *Processed*:** Após a conclusão do processamento e da carga no banco de dados, os arquivos finais são transferidos para a zona *processed*, indicando que a etapa ETL foi finalizada.

Problemas de Armazenamento no MinIO

O MinIO frequentemente enfrenta problemas de sobrecarga e de integração, com ambientes de produção por exemplo, devido a restrição dos dados e a iL é izarelacionada ao volume amplo de dados de dados. Esse problema de restrição ocorre por uma organização inadequada dos *buckets* e da ausência de uma estrutura padronizada de armazenamento. Vários processos acabam compartilhando *buckets* sem um isolamento específico, o que causa dificuldades em identificar corretamente cada etapa e dificulta o acesso ao armazenamento, principalmente no ambiente de produção. A sobrecarga do armazenamento também implica em atrasos e falhas no sistema de ETL, aumentando a possibilidade de indisponibilidade dos dados. Como o Minio era utilizado como

um repositório data lake, esse repositório por sua definição pode conter uma grande diversidade de dados, desde estruturados a não estruturados, arquivos, entre outros, mas necessariamente um data lake necessita de uma organização de armazenamento de dados, para possíveis consultas, que necessitam ser otimizadas por exemplo, persistência de dados, entre outros, e essa desorganização também impactava negativamente essas questões abordadas.

Após uma estruturação correta do repositório data lake, foi possível mitigar problemas de processamento e consulta de dados, problemas relacionados a questões de segurança dos buckets que estavam centralizados e devidamente gerenciados de maneira correta, etc.

2. Transformação dos Dados

Na fase de transformação, os dados passam por um processo de tratamento e organização para que estejam prontos para a ingestão no banco de dados. Abaixo estão os detalhes das principais transformações aplicadas:

- **Conversão de Datas e Formatação:** Como muitas informações contêm dados temporais, padronizamos as datas para uma única zona de tempo, garantindo consistência entre as consultas e relatórios futuros.
- **Estruturação e Organização:** Utilizamos o pandas para transformar os dados, convertendo o JSON em DataFrames, o que facilita a manipulação, limpeza e formatação dos dados antes de serem exportados para CSV.
- **Exportação para CSV:** Após o tratamento com pandas, os dados são convertidos para o formato CSV, o que otimiza a etapa de carga, já que o CSV oferece maior compatibilidade com o banco de dados e facilita a definição de um esquema tabular.

Problemas na Transformação dos Dados

Uma limitação significativa desse processo é a necessidade de manter um esquema de dados rígido. Alterações no esquema, como a adição de novos atributos ou campos, exigem que o ETL seja executado novamente, o que demanda recursos e tempo. A falta de flexibilidade do processo dificulta a adaptação a novas demandas de dados, como a inclusão de novos relatórios ou atributos, tornando o processo de atualização moroso e com risco de inconsistências nos dados.

3. Definição do Esquema e Carga no Banco de Dados

Na última etapa do ETL, os dados transformados em CSV são ingeridos no banco de dados. Aqui, definimos o esquema completo da tabela, incluindo:

- **Chaves Primárias e Estrutura de Chaves Estrangeiras:** Definimos as chaves primárias e, quando necessário, as relações entre tabelas por meio de chaves estrangeiras.
- **Normalização dos Dados:** Aplicamos regras de normalização para evitar redundâncias e inconsistências. Essa etapa é crítica para manter a integridade dos dados e facilitar consultas mais rápidas e eficazes.

Após a ingestão, movemos o arquivo da área *processing* para a área *processed* no MinIO. Este processo confirma que o ETL foi concluído com sucesso e que os dados já estão disponíveis para consulta e análise.

Problemas na Carga e Manutenção do Esquema

A rigidez na definição do esquema torna difícil adaptar-se a mudanças. Caso seja necessário adicionar um campo, o processo de carga e normalização precisa ser refeito para todas as tabelas afetadas. Além disso, a falta de flexibilidade para incluir novas fontes de dados de forma dinâmica é uma limitação grave, especialmente para cenários de grande variabilidade de dados.

4. Geração de Relatórios e Ferramentas de Relatório

Para atender às demandas de relatórios, utilizamos uma abordagem manual de geração de PDFs, o que envolve a utilização de HTML e CSS para estruturar os relatórios. No entanto, esta abordagem tem problemas de escalabilidade e flexibilidade, pois cada novo tipo de relatório demanda um esforço significativo de desenvolvimento e atualização. Esta etapa tornou-se um gargalo, especialmente quando há a necessidade de múltiplos tipos de relatórios personalizados ou quando há requisitos de atualização frequente nos relatórios existentes.

A geração de relatórios é uma etapa crítica para transformar dados em insights acionáveis e garantir suporte às decisões estratégicas. No entanto, os desafios associados a abordagens manuais, como a necessidade de gerar PDFs estáticos, podem limitar a escalabilidade, flexibilidade e capacidade analítica do sistema. Uma abordagem modernizada e automatizada pode trazer benefícios significativos ao adotar ferramentas robustas e relatórios dinâmicos. Abaixo estão os detalhes dessas melhorias:

1. Automação de Relatórios

A automação é essencial para reduzir a carga manual na geração de relatórios e garantir consistência e eficiência. Ferramentas modernas possibilitam a integração direta com a camada **Gold** da arquitetura ELT, otimizando o processo de produção e distribuição de relatórios.

As ferramentas adotadas em alternativa para a geração e consolidação de relatórios e dashboards foram:

1. **Metabase** (Open Source):

- **Características:** Metabase permite criar dashboards e relatórios dinâmicos com uma interface amigável e sem a necessidade de conhecimento profundo de SQL.
- **Integração com a Camada Gold:** Conecta-se diretamente a bancos de dados como PostgreSQL, permitindo acesso direto aos dados finais já transformados e validados.
- **Automação:** Relatórios podem ser agendados para envio por e-mail ou outras integrações (Slack, webhook).
- **Interatividade:** Usuários podem aplicar filtros e realizar consultas customizadas em tempo real, reduzindo a necessidade de relatórios predefinidos.

2. **Power BI:**

- **Características:** Uma das ferramentas mais populares para relatórios e análises, com funcionalidades avançadas de modelagem de dados e visualizações interativas.
- **Automação:** Atualizações automáticas de dados conectados à camada Gold e publicação agendada de relatórios.
- **Exportação Dinâmica:** Relatórios podem ser convertidos para diferentes formatos (PDF, Excel) sem perder a interatividade.

2. Relatórios Dinâmicos

Relatórios dinâmicos substituem os PDFs estáticos tradicionais, permitindo que os usuários interajam diretamente com os dados. Isso aumenta a capacidade de análise e reduz o tempo necessário para gerar novos relatórios.

Vantagens dos Relatórios Dinâmicos:

1. **Interatividade**

- **Filtros Personalizados:** Os usuários podem aplicar filtros em tempo real (e.g., selecionar datas específicas, categorias ou regiões).
- **Drill-Down:** Permite explorar níveis mais detalhados dos dados diretamente no relatório, como navegar de um total agregado para registros individuais.

- **Dashboards Centralizados:** Relatórios dinâmicos podem ser incorporados em dashboards, fornecendo uma visão consolidada de KPIs e métricas em um único lugar.

2. Agilidade e Atualização Contínua:

- **Atualização Automática:** Relatórios dinâmicos podem ser configurados para se atualizarem automaticamente com os dados mais recentes da camada Gold, eliminando a necessidade de regenerar relatórios manualmente.
- **Respostas em Tempo Real:** Usuários podem explorar e analisar dados em tempo real sem depender de equipes de TI ou analistas para gerar relatórios adicionais.

3. Acessibilidade:

- **Interfaces Web:** Relatórios podem ser acessados diretamente por navegadores, garantindo que as partes interessadas tenham acesso rápido e fácil aos insights.
- **Colaboração:** Ferramentas modernas permitem compartilhar relatórios com equipes ou exportá-los em formatos ajustados às necessidades (e.g., Excel para análises adicionais).

3. Integração com a Arquitetura ELT

A integração de ferramentas de relatórios dinâmicos com a camada Gold facilita a automação e mantém a consistência das informações.

- **Conexão Direta:** Ferramentas como Metabase acessam diretamente os dados transformados na camada Gold, eliminando a necessidade de extração e manipulação externa.
- **Validação de Dados:** Como os dados já passaram por testes e validações no DBT, a qualidade dos relatórios gerados é garantida.
- **Monitoramento de Atualizações:** As ferramentas são configuradas para sincronizar com a camada Gold periodicamente, garantindo que os relatórios refletem sempre os dados mais recentes.

4. Escalabilidade e Governança

Ferramentas modernas permitem que relatórios e dashboards sejam escaláveis e atendam a várias necessidades organizacionais:

- **Escalabilidade:** Dashboards dinâmicos podem suportar centenas de usuários simultaneamente sem gerar sobrecarga significativa.

- **Governança:** Acesso controlado pode ser configurado para diferentes níveis hierárquicos, garantindo que apenas usuários autorizados vejam informações sensíveis.

A migração de relatórios estáticos para um modelo dinâmico e automatizado ofereceu melhorias significativas em eficiência, flexibilidade e usabilidade. Ferramentas modernas como Metabase, Power BI permitiram o time criar relatórios interativos que se adaptam às necessidades dos usuários em tempo real, enquanto a automação reduz o trabalho manual e erros associados. Essa abordagem não apenas moderniza a geração de relatórios, mas também potencializa a capacidade analítica da organização, tornando os dados mais acessíveis e úteis para todos os stakeholders.

Airflow e o Uso Ineficiente no Processo de ETL

O Airflow, projetado para orquestrar processos ETL em lotes, tem sido utilizado incorretamente como um sistema de streaming para requisições de dados em tempo real. Este uso inadequado resultou em grandes dificuldades de escalabilidade e flexibilidade. O Airflow, embora poderoso para agendar e monitorar fluxos de dados, não é otimizado para uma abordagem contínua de streaming, causando sobrecarga nos processos e levando a falhas frequentes em cenários de grandes volumes de dados.

Limitações do Airflow

Esse uso incorreto do Airflow afeta diretamente a escalabilidade do sistema. Em vez de aproveitar a arquitetura de lotes, que permite um processamento eficiente de grandes quantidades de dados em intervalos regulares, o sistema tenta requisitar dados continuamente, sobrecarregando o Airflow e dificultando o gerenciamento de falhas e a recuperação de dados.

Banco de Dados e Dificuldades de Acesso

A nossa solução de banco de dados é mantida por uma empresa terceirizada especializada em bancos de dados para órgãos públicos. Esta estrutura de terceiros, no entanto, apresenta desafios significativos de disponibilidade e acessibilidade devido ao alto volume de requisições e limitações de acesso.

Para mitigar parte desses problemas, replicamos o banco de dados original em uma instância com permissões de consulta. Isso permite que façamos leituras e análises sem depender da estrutura de produção original. No entanto, a réplica não permite operações de escrita, o que nos impede de realizar ajustes e manipulações mais complexas nos dados. Além disso, um banco de dados próprio poderia nos fornecer maior autonomia para definir esquemas, realizar otimizações e personalizar conforme as necessidades específicas dos processos.

Arquitetura Atualizada com Processo ELT

Na arquitetura anterior, implementamos uma abordagem baseada em ETL (Extração, Transformação e Carga), que representa uma evolução significativa em relação ao modelo anterior. Essa transição trouxe avanços notáveis em termos de eficiência operacional, segurança, flexibilidade e escalabilidade. A estrutura modular do ELT permite lidar de forma mais eficaz com volumes crescentes de dados, reduzindo a complexidade do pipeline e otimizando as etapas de ingestão e processamento. A seguir, detalhamos as principais melhorias e benefícios alcançados com essa mudança estratégica.

1. Escalabilidade e Volume de Dados

- **Cenário Atual:** O crescimento exponencial de dados exige soluções mais robustas para processá-los em grande escala.
- **Problema no ETL:** O processamento transformacional ocorre antes da carga, o que limita a escalabilidade devido à dependência de ferramentas locais ou pipelines centralizados.
- **Como o ELT resolve:** O ELT aproveita a capacidade de armazenamento e processamento de dados brutos diretamente em data lakes e data warehouses modernos. Isso permite lidar com volumes crescentes de dados de forma eficiente, usando a infraestrutura distribuída desses sistemas.

2. Flexibilidade para Novas Demandas de Dados

- **Cenário Atual:** O mercado exige análises rápidas e dinâmicas, além da integração de novas fontes de dados com frequência.
- **Problema no ETL:** Alterações no esquema ou na estrutura dos dados requerem retrabalho significativo, já que o pipeline precisa ser redesenhado para incluir novas transformações antes da carga.
- **Como o ELT resolve:** No ELT, os dados são armazenados na camada raw no formato original, sem transformações iniciais. Isso facilita a inclusão de novas fontes ou atributos, pois a transformação é feita conforme necessário, sem reprocessar etapas anteriores.

3. Maior Aproveitamento de Recursos Existentes

- **Cenário Atual:** Ferramentas tradicionais de ETL podem consumir recursos significativos para manipular grandes volumes de dados, exigindo hardware dedicado ou soluções locais.

- **Problema no ETL:** A execução de transformações fora de um data warehouse ou lakehouse força o uso de recursos locais limitados, o que aumenta custos e complexidade.
- **Como o ELT resolve:** O ELT utiliza diretamente o poder de processamento das ferramentas de armazenamento modernas (como Snowflake, BigQuery, ou mesmo PostgreSQL). Isso reduz a necessidade de recursos externos e centraliza as operações em infraestruturas escaláveis.

4. Otimização de Tempo e Performance

- **Cenário Atual:** As organizações precisam de pipelines de dados que suportem cargas rápidas e análises em tempo quase real.
- **Problema no ETL:** A execução de transformações fora do destino final gera latência adicional, aumentando o tempo necessário para disponibilizar os dados.
- **Como o ELT resolve:** Ao carregar dados brutos diretamente na camada raw e realizar transformações conforme necessário, o ELT reduz os tempos de ingestão e prioriza a transformação apenas para dados que serão usados em análises específicas.

5. Redução de Complexidade Operacional

- **Cenário Atual:** O processo ETL tradicional requer pipelines sequenciais complexos, muitas vezes difíceis de manter e monitorar.
- **Problema no ETL:** A dependência de ferramentas intermediárias e o acoplamento entre as etapas dificultam a manutenção e a recuperação em caso de falhas.
- **Como o ELT resolve:** O ELT desacopla a ingestão de dados das transformações, simplificando os pipelines e permitindo que cada etapa seja gerenciada de forma independente. Isso melhora a confiabilidade e a capacidade de monitoramento.

6. Melhor Governança e Qualidade de Dados

- **Cenário Atual:** Governança e controle de qualidade são essenciais para a confiabilidade e conformidade com regulamentos (e.g., LGPD, GDPR).
- **Problema no ETL:** A transformação antecipada pode ocultar erros ou inconsistências nos dados brutos, dificultando auditorias e a rastreabilidade dos dados.
- **Como o ELT resolve:** No ELT, os dados brutos ficam armazenados na camada raw, garantindo uma fonte de verdade que pode ser consultada e

auditada. Além disso, as transformações posteriores podem ser validadas e testadas com frameworks modernos, como DBT, garantindo a consistência.

7. Integração com Arquiteturas Modernas

- **Cenário Atual:** As organizações estão migrando para data warehouses em nuvem ou híbridos que oferecem recursos avançados para análise e armazenamento de dados.
- **Problema no ETL:** Ferramentas ETL tradicionais nem sempre integram bem com arquiteturas modernas baseadas em cloud ou data lakehouses.
- **Como o ELT resolve:** O ELT aproveita os recursos nativos dessas plataformas (como transformação SQL em data warehouses ou integração nativa com lakes) para fornecer uma experiência integrada e otimizada.

8. Custo-Efetividade

- **Cenário Atual:** A redução de custos é uma prioridade em qualquer arquitetura moderna de dados.
- **Problema no ETL:** A dependência de ferramentas específicas para transformações e a necessidade de infraestrutura dedicada para processar dados fora do destino final aumentam os custos operacionais.
- **Como o ELT resolve:** Ao usar a capacidade nativa de processamento dos sistemas de armazenamento, o ELT elimina a necessidade de infraestrutura redundante e ferramentas caras, reduzindo significativamente os custos.

9. Preparação para Processamento em Tempo Real

- **Cenário Atual:** Com a crescente demanda por análises em tempo real, a arquitetura precisa ser flexível para lidar com lotes e streaming.
- **Problema no ETL:** O pipeline sequencial de ETL não é adequado para processamento contínuo ou em tempo real.
- **Como o ELT resolve:** O ELT pode ser complementado com ferramentas de streaming (como Apache Spark Streaming ou Kafka) para transformar dados diretamente durante o consumo, adicionando agilidade e valor.

1. Extração e Carga de Dados na Camada RAW

O processo começa com a extração dos dados a partir de um banco de dados réplica de origem, onde estão disponíveis as informações iniciais. Esse banco de origem atua como uma fonte segura e atualizada dos dados, que são então carregados diretamente para o nosso banco de dados de destino, na camada

RAW. Essa camada serve como um repositório bruto, onde os dados são armazenados exatamente como foram extraídos, sem qualquer transformação ou modificação.

Automação com DAGs no Airflow

Para garantir a automação e periodicidade desse processo, utilizamos DAGs (Directed Acyclic Graphs) no Airflow. Os DAGs são configurados para rodar periodicamente, assegurando que os dados na camada RAW estejam sempre atualizados e disponíveis para processamento. Atualmente, o Airflow está configurado de forma otimizada para esse fluxo, e as DAGs estão operando corretamente, garantindo uma execução consistente e estável do processo de ingestão.

2. Transformação com Modelos DBT e Camadas Silver e Gold

Com os dados ingeridos na camada RAW, o processo de transformação é conduzido através de modelos DBT (Data Build Tool). O DBT permite modelar, transformar e validar os dados de forma estruturada, resultando em um processo mais confiável e com maior controle de qualidade. A arquitetura ELT é organizada nas seguintes camadas:

- **Camada Silver:** Após a transformação inicial, os dados são movidos para a camada Silver, onde passam por uma estruturação intermediária. Nessa camada, os dados são organizados, limpos e padronizados, atendendo a regras de negócio e garantindo que estejam prontos para consultas mais complexas. Essa estrutura intermediária é útil para agregar dados, validar informações e realizar correções de inconsistências de forma simplificada.
- **Camada Gold:** Após a organização e validação na camada Silver, os dados são finalmente transformados e enviados para a camada Gold. Esta camada é a mais refinada e contém os dados finais, já prontos para análises e relatórios. Nela, os dados são otimizados para consultas analíticas e estão organizados de acordo com o modelo de dados necessário para as tomadas de decisão. A camada Gold é acessada diretamente por dashboards, relatórios e outras ferramentas analíticas.

Detalhamento dos Benefícios do DBT (Data Build Tool)

O **DBT (Data Build Tool)** é uma ferramenta poderosa e amplamente utilizada para transformar dados diretamente dentro de data warehouses e data lakes, trazendo organização, consistência e controle ao processo de modelagem de dados. A seguir, detalhamos seus benefícios, destacando como ele pode otimizar pipelines

e elevar o nível de governança e qualidade de dados em suas respectivas arquiteturas:

1. Testes Automatizados

Um dos grandes diferenciais do DBT é sua capacidade de automatizar testes de qualidade, assegurando a consistência e a integridade dos dados em cada etapa da transformação.

- **Validação de Dados:** O DBT permite configurar e executar testes de validação diretamente nos modelos, como verificar valores nulos, unicidade de chaves primárias e conformidade de tipos de dados. Isso reduz erros e inconsistências nos dados processados.
- **Testes Customizados:** Além dos testes padrão, é possível criar **testes personalizados** para regras de negócio específicas, garantindo que os dados estejam alinhados com os requisitos da organização.
- **Execução Contínua:** Em pipelines configurados com **CI/CD**, os testes podem ser executados automaticamente antes de publicar transformações no ambiente de produção. Isso evita que dados incorretos ou transformações falhas sejam propagados.
- **Relatórios de Falhas:** Quando um teste falha, o DBT fornece feedback detalhado com logs e rastreamento, facilitando a identificação e correção de problemas rapidamente.

2. Auditoria e Documentação Automatizada

O DBT possui ferramentas nativas que criam documentação rica e automatizada para todo o pipeline de transformação, aumentando a governança e a transparência.

- **Catálogo de Dados:** O DBT gera automaticamente um **data catalog** que inclui informações sobre cada modelo, colunas, descrições, fontes de dados e dependências. Isso facilita a navegação e compreensão de como os dados são processados e estruturados.
- **Rastreabilidade Completa:** Através de seu mecanismo de lineage (linhagem de dados), o DBT permite rastrear a origem de cada dado até a fonte inicial. Isso é crucial para auditorias e análises retrospectivas.
- **Visualizações Interativas:** O catálogo do DBT pode ser acessado via interface web, permitindo que equipes técnicas e não técnicas explorem os modelos e compreendam o fluxo de dados de forma intuitiva.

- **Histórico de Alterações:** Como o DBT trabalha diretamente com controle de versão, todas as mudanças nos modelos são rastreadas, permitindo auditorias robustas e revertendo facilmente a estados anteriores em caso de necessidade.

3. Incremental Models

O DBT oferece suporte nativo para **modelos incrementais**, que otimizam a transformação ao processar apenas dados novos ou alterados, em vez de reprocessar o conjunto completo.

- **Eficiência de Processamento:**
 - Ao trabalhar com grandes volumes de dados, reprocessar toda a tabela pode ser custoso e demorado. Os modelos incrementais permitem adicionar apenas os dados mais recentes ou atualizados, reduzindo significativamente o tempo de execução.
 - Essa abordagem é especialmente útil em pipelines que lidam com dados de streaming ou integrações regulares de novas entradas.
- **Configuração Simples:**
 - Com apenas algumas configurações no arquivo SQL do modelo, o DBT permite definir critérios para identificar quais dados devem ser adicionados ou atualizados.
 - Por exemplo, você pode usar colunas de timestamp para carregar apenas dados modificados após a última execução.
- **Redução de Custos:**
 - O processamento incremental diminui o uso de recursos computacionais, o que é essencial em ambientes de data warehouses na nuvem, como Snowflake ou BigQuery, onde custos estão associados ao volume de dados processados.
- **Flexibilidade para Atualizações Parciais:**
 - Os modelos incrementais também permitem gerenciar atualizações parciais, como corrigir dados históricos sem precisar processar toda a tabela.

4. Colaboração e Reutilização

O DBT facilita a colaboração entre equipes e promove a reutilização de modelos e transformações:

- **Modularidade dos Modelos:**

- Modelos podem ser criados como **módulos reutilizáveis**, permitindo que outras equipes ou pipelines utilizem as mesmas transformações em diferentes contextos.
- Por exemplo, um modelo de transformação para cálculos financeiros pode ser usado em relatórios diferentes sem necessidade de duplicação de lógica.
- **Colaboração via Git:**
 - Com integração nativa ao Git, o DBT permite que equipes colaborem no desenvolvimento de modelos, revisem alterações e implementem melhores práticas de controle de versão.
- **Consistência entre Ambientes:**
 - O DBT assegura que os mesmos modelos e transformações sejam aplicados em ambientes de desenvolvimento, teste e produção, evitando inconsistências ou desvios.

5. Integração com Arquiteturas Modernas

O DBT foi projetado para funcionar com os principais data warehouses e plataformas de análise modernas:

- **Compatibilidade Ampla:** O DBT suporta ferramentas como Snowflake, BigQuery, Redshift, Databricks e PostgreSQL, entre outras, permitindo sua integração em diferentes cenários de arquitetura.
- **Execução no Warehouse:** Todas as transformações são executadas diretamente no data warehouse, aproveitando o poder de processamento nativo da plataforma e reduzindo a dependência de ferramentas externas.
- **Suporte a SQL:** Ao trabalhar diretamente com SQL, o DBT reduz a curva de aprendizado para equipes que já estão familiarizadas com consultas estruturadas.

6. Qualidade e Governança Integradas

O DBT não é apenas uma ferramenta de transformação, mas também um framework de governança que promove a qualidade contínua dos dados:

- **Testes Contínuos:** A execução regular de testes assegura que os dados estejam sempre consistentes, mesmo em face de mudanças na estrutura.
- **Padronização de Processos:** O uso de modelos SQL padronizados promove consistência em toda a organização, reduzindo erros e garantindo alinhamento com as regras de negócio.

- **Redução de Retrabalho:** Com documentações detalhadas e validações integradas, o DBT diminui erros e retrabalhos em ciclos futuros.

Adendo:

Apesar de a arquitetura atual não demandar necessariamente o uso do **Apache Spark**, ele será implementado para atender a duas finalidades principais: fins acadêmicos e suporte a serviços com necessidade de processamento em **streaming**.

Apache Spark na Arquitetura Atual

O Spark será integrado à arquitetura como um complemento ao fluxo ELT, trazendo capacidades adicionais para o tratamento de dados em streaming e processamento distribuído. Esse componente permitirá que dados sejam processados em tempo real, agregando valor para cenários que demandem respostas instantâneas, como a detecção de eventos e análises em tempo real.

Fins Acadêmicos e Experimentos

O uso do Spark permitirá o estudo e experimentação de processamento distribuído, escalabilidade e alta performance, oferecendo uma visão prática das vantagens e limitações do Spark em um ambiente real de dados. Esse aprendizado contribuirá para uma maior versatilidade no gerenciamento de dados e na adaptação da arquitetura para futuras demandas.

Suporte a Serviços de Streaming

Embora o foco atual seja o processamento em lotes com Airflow e DBT, o Spark será utilizado para gerenciar dados em streaming para serviços que exigem informações em tempo real. Integrado com fontes de dados contínuas, como filas de mensagens, o Spark possibilitará a ingestão, transformação e análise de dados em tempo real, complementando as camadas Silver e Gold com dados atualizados continuamente.

Benefícios e Desafios

A inclusão do Spark trará à arquitetura uma camada adicional de processamento de dados em tempo real, ampliando a flexibilidade e a capacidade de resposta da infraestrutura. Contudo, esse acréscimo implica na necessidade de configuração e monitoramento adicionais para garantir que o Spark se integre bem ao fluxo de dados já estabelecido.

Essa implementação permitirá explorar uma arquitetura robusta, onde coexistem processamento em lotes e em tempo real, tornando-a adaptável tanto para aprendizado acadêmico quanto para o atendimento de demandas práticas futuras.

