

Introdução

O Brasil Participativo é uma iniciativa do governo brasileiro que promove a participação social e a transparência, criando um canal direto para que os cidadãos possam contribuir, sugerir e acompanhar a formulação de políticas públicas. Através de uma plataforma digital acessível e inclusiva, a população é convidada a interagir com temas relevantes, como educação, saúde, meio ambiente, segurança e desenvolvimento econômico, influenciando as prioridades e ações do governo de forma colaborativa.

Neste contexto, o Time de Serviços De Dados desempenha um papel essencial ao fornecer a infraestrutura e as automações que sustentam a plataforma e suportam a gestão baseada em dados dos processos participativos. Com foco em uma arquitetura de dados moderna, o time adota o conceito de Data Mesh, que permite uma gestão distribuída e colaborativa dos dados. Este modelo possibilita que as informações sejam administradas de forma descentralizada, facilitando o acesso e a transparência para gestores e população.

Além disso, o Time de Serviços De Dados é responsável pela criação de automações que otimizam o fluxo de informações, reduzindo o esforço manual, e em soluções de Business Intelligence (BI), que fornece insights valiosos para gestores e diretores na tomada de decisões.

Em suma, o Time de Serviços De Dados é fundamental para o Brasil Participativo, pois permite que o projeto seja sustentado por dados confiáveis e acessíveis, promovendo um ambiente colaborativo e transparente que fortalece a participação ativa dos cidadãos e a eficiência do governo em atender às demandas sociais.

Ferramentas

Para o projeto Brasil Participativo, as ferramentas escolhidas — Airflow, Metabase, PostgreSQL, MLFlow e DBT foram selecionadas com base em suas funcionalidades robustas, escalabilidade, e sua adequação às necessidades específicas de uma plataforma voltada para a participação social e a transparência governamental. Abaixo, segue uma análise detalhada das ferramentas, explicando o motivo de cada escolha, bem como comparações com alternativas.

Airflow

O Airflow é uma plataforma de gerenciamento de workflows muito utilizada para orquestrar pipelines de dados de maneira eficiente. Para o Brasil Participativo, ele é essencial para automação e gerenciamento dos fluxos de dados que integram,

transformam e carregam informações nas diferentes camadas da arquitetura Medallion.

Comparação com outras ferramentas:

Luigi: Embora seja uma alternativa para gerenciamento de workflows, o Luigi é mais adequado para pipelines de dados menos complexos e com uma necessidade menor de interdependência entre tarefas.

Prefect: Prefect oferece recursos avançados para controle de tarefas, com foco em uma interface mais amigável. Contudo, pode se tornar mais custoso em termos de configuração para projetos que requerem um fluxo extenso de dados como o Brasil Participativo.

A maturidade e a comunidade ativa do Airflow, somadas à sua robustez em tarefas complexas e dependências entre processos, tornam-no ideal para este projeto. Ele proporciona a automação e a agilidade necessárias para monitoramento e manutenção dos fluxos de dados com eficiência.

Metabase

Metabase é uma ferramenta de BI intuitiva e de código aberto que facilita a criação de dashboards e relatórios para visualização de dados. No contexto do Brasil Participativo, o Metabase permite a criação de relatórios acessíveis e de fácil entendimento, voltados para a população e para gestores governamentais.

Comparação com outras ferramentas:

Tableau: Tableau é uma das principais ferramentas de BI, reconhecida pela sua rica interface gráfica e variedade de visualizações. No entanto, seu custo pode ser uma barreira em projetos que buscam alternativas de código aberto.

Power BI: Power BI é robusto e fornece excelente suporte para visualização de dados e integração com outras ferramentas do Microsoft Ecosystem. Porém, o Metabase oferece uma curva de aprendizado mais simples e uma implantação rápida com menor custo.

Metabase atende ao requisito de acessibilidade e transparência de dados do Brasil Participativo, com a vantagem de ser open-source, intuitivo, e de fácil integração com bancos de dados, o que facilita a criação de visualizações e insights sem a necessidade de custos elevados.

PostgreSQL

PostgreSQL é um banco de dados relacional poderoso e open-source que oferece grande flexibilidade e confiabilidade para armazenamento de dados. Ele é particularmente importante para a camada Prata da arquitetura, onde os dados

são padronizados e precisam de um sistema de banco de dados que ofereça consultas rápidas e suporte para transações complexas.

Comparação com outras ferramentas:

MySQL: Embora seja amplamente utilizado, o MySQL possui limitações quando comparado ao PostgreSQL no que tange ao suporte a operações complexas e à extensibilidade. Além disso, o PostgreSQL é mais robusto para análises de dados e manipulação de grandes volumes de dados transacionais. - [MySQL vs PostgreSQL Performance Benchmark \(Latency - Throughput - Saturation\)](#)

Oracle: Oracle Database é uma solução premium e oferece recursos avançados para empresas que necessitam de suporte para grandes cargas de trabalho e alto desempenho. Entretanto, seu custo e complexidade de manutenção tornam-no menos atrativo para uma iniciativa pública como o Brasil Participativo.

Com sua excelente performance, suporte a transações avançadas, e capacidade para manipulação de grandes volumes de dados, o PostgreSQL é ideal para o Brasil Participativo, oferecendo uma solução open-source robusta e confiável, que suporta o armazenamento e acesso eficiente aos dados da camada Prata.

MLFlow

MLFlow é uma plataforma de gerenciamento de experimentos e modelos de Machine Learning (ML) que facilita o rastreamento de experimentos, a reprodução de resultados, e o monitoramento de modelos em produção. No Brasil Participativo, o MLFlow auxilia na camada Ouro da arquitetura, onde modelos avançados de IA podem ser aplicados para análise preditiva e geração de insights.

Comparação com outras ferramentas:

TensorBoard: Embora seja útil para experimentação, o TensorBoard tem limitações no monitoramento e na gestão de modelos em produção, sendo mais voltado para visualização de treinamento de redes neurais.

Kubeflow: Kubeflow é uma alternativa mais completa para orquestração de pipelines de ML. No entanto, ele requer maior complexidade e infraestrutura, o que pode ser desnecessário no escopo atual do Brasil Participativo.

O MLFlow é uma escolha prática e leve para a gestão dos modelos de aprendizado de máquina, oferecendo a simplicidade e eficiência necessárias para monitorar experimentos e acompanhar a produção de insights, sem a complexidade extra do Kubeflow.

DBT - (Data Build Tool)

O DBT é uma ferramenta de transformação de dados que permite que analistas definem e compartilhem transformações diretamente em SQL, facilitando o fluxo de dados na arquitetura Medallion.

Comparação com outras ferramentas:

Apache Spark (Standalone): Apache Spark oferece uma plataforma robusta para processamento de dados em larga escala. No entanto, o DBT permite um desenvolvimento mais próximo dos analistas, tornando o processo de transformação de dados mais ágil e colaborativo.

Talend: Talend é uma ferramenta de integração de dados com uma abordagem mais focada em ETL visual. Embora completa, ela não possui a mesma proximidade com SQL e o foco em transformação que o DBT oferece, além de ser uma solução mais pesada.

A simplicidade e integração que o DBT oferece com Databricks tornam essa escolha ideal para o Brasil Participativo, promovendo uma abordagem modular e colaborativa para transformação de dados, com flexibilidade para escalar conforme necessário e suporte para uma implementação futura de Data Mesh.

A escolha dessas ferramentas para o Brasil Participativo é baseada em critérios de escalabilidade, integração e custo-efetividade, garantindo que o Time de Dados possa fornecer informações estratégicas e acessíveis para gestores e população.

Arquitetura

A arquitetura de dados do projeto Brasil Participativo segue o modelo **Medallion Architecture**, que estrutura e qualifica os dados em diferentes camadas para oferecer maior valor e organização. Esta abordagem organiza os dados em três níveis principais – **Bronze, Prata e Ouro** – cada um com uma função específica no processo de tratamento e aproveitamento de dados, facilitando o acesso e o uso estratégico pelas equipes e possibilitando análises de qualidade para a gestão e para os cidadãos. Abaixo, detalhamos cada camada e as ferramentas escolhidas para operacionalizar essa arquitetura.

Além disso, é possível a implementação de **Data Mesh**, que prioriza uma gestão descentralizada e colaborativa de dados ao dividir a arquitetura em domínios independentes, cada um responsável por seus próprios dados. Embora essa estrutura seja viável e favorecida pela **Medallion Architecture**, no caso do Brasil Participativo, até o momento, a implementação completa de um Data Mesh ainda não é necessária devido à ausência de múltiplos domínios distintos dentro do projeto. Com a Medallion Architecture, o projeto ainda se beneficia de uma estrutura organizada e escalável, pronta para suportar um modelo de Data Mesh caso a expansão futura exija.

Camada Bronze

A camada **Bronze** é composta por dados brutos, integrados diretamente de várias fontes, como bancos de dados transacionais, APIs, fluxos de dados em tempo real ou cargas em lote. Nesse estágio, os dados são mantidos em seu estado original, sem transformações ou filtrações, o que preserva a integridade das informações para consulta futura ou auditoria.

- **Ferramentas:** As ferramentas escolhidas para armazenar e gerenciar esses dados incluem sistemas de **data lakes** escaláveis, como o **MinIO**, que possibilitam armazenamento seguro e eficiente de grandes volumes de dados não estruturados ou semiestruturados.

Camada Prata

A camada **Prata** recebe os dados após uma etapa inicial de limpeza e padronização, permitindo que se tornem mais acessíveis e consistentes. Nessa fase, os dados são tratados para remoção de inconsistências, normalização e padronização de formatos, o que facilita a consulta e análise por diversos setores. Essa camada fornece uma visão refinada dos dados, ainda que sem transformações profundas, atendendo às necessidades de processos intermediários de análise.

- **Ferramentas:** Utilizamos ferramentas de processamento como o **Apache Spark** e o **Databricks**, que oferecem poderosos recursos de transformação e limpeza de dados em grande escala. Além disso, armazenamos os dados dessa camada em **data warehouses** como o **PostgreSQL** para otimizar o acesso e a consulta.

Camada Ouro

Os dados na camada **Ouro** passam por transformações e agregações adicionais, tornando-se altamente valiosos para a análise avançada. Nesta etapa, os dados estão prontos para alimentar modelos de **Machine Learning** e **Inteligência Artificial** ou para serem usados em painéis de **Business Intelligence (BI)**, auxiliando na geração de insights acionáveis para a tomada de decisão e monitoramento de políticas públicas. Nessa camada, os dados são otimizados para analistas de negócios e cientistas de dados, oferecendo uma visão estratégica e de alto valor agregado.

- **Ferramentas:** Para essa camada, adotamos **ferramentas de BI** como **Metabase** e **Power BI** para visualização e análise, permitindo que os gestores acompanhem os KPIs e tendências dos processos participativos.

A aplicação da **Medallion Architecture** no projeto Brasil Participativo permite que os dados fluam de maneira estruturada e segura por cada camada, desde o

estágio bruto até a análise avançada. Essa abordagem, somada às ferramentas escolhidas, garante que o time de dados possa fornecer informações precisas, acessíveis e estratégicas para as diferentes áreas do programa. Dessa forma, o Brasil Participativo não só promove a transparência e acessibilidade dos dados para a população, mas também assegura que os gestores públicos tenham à disposição dados consistentes para uma governança mais eficiente e informada. Além disso, essa arquitetura oferece flexibilidade para a implementação de um modelo de **Data Mesh** no futuro, caso o projeto expanda para múltiplos domínios de dados.

pipeline e Serviços de dados.. aqui pode falar dos conceitos e pq escolhemos isso